

리서치센터 리포트
바로가기

글로벌 AI

중국 AI 업데이트. Kimi에 이어 GLM과 Qwen

- 문샷 AI의 Kimi K3 출시 이후 중국 AI 모델의 업데이트를 주도하는 것은 Z AI의 GLM과 알리바바 Qwen. 최근 Z AI와 미니맥스는 26년 상반기 실적을 발표
- 작업 당 비용 기준 미국과 중국 AI 모델의 포지션은 상당히 혼재된 상황. 중국 모델의 오픈웨이트 내 상업적 조건 추가도 특징적인 변화

WHAT'S THE STORY?

Kimi K3의 시사점: 문샷 AI의 Kimi K3는 중국 AI 모델이 본격적인 프론티어 경쟁에 돌입하는 시작점. 2.8T 파라미터로 오픈웨이트 최대 규모를 기록하며 반도체 규제에 따라 불가능해 보였던 스케일링에도 성공. 물론 높지 않은 API 가격에도 불구하고 대규모 토큰 사용에 따라 작업당 비용의 강점은 희석. 과추론, 느린 속도, 벤치마크 대비 부진한 실체감, 유저 경험 측면의 격차와 같은 단점도 존재

Kimi에 이어 GLM과 Qwen: Kimi K3는 아직까지 AAI 점수 기준 중국 모델 1위 자리를 지키고 있지만, 이후 중국 AI 모델의 업데이트를 주도하는 것은 Z AI의 GLM과 알리바바의 Qwen. GLM-5.3은 GLM-5.2(743B)와 동일한 베이스 모델을 활용하고도 사후학습 및 장기 RL 스케일링만으로 성능 개선. Ox Alpha라는 이름으로 테스트된 GLM-5.3-Flash는 320B(활성 18B)의 작은 규모에도 프론티어 모델과 격차를 상당부분 축소

알리바바 Qwen 3.8 시리즈는 대형 모델(2.4T)와 소형 모델(27B)로 분화하는 전략. 또한 차세대 Qwen 4에 적용될 신규 아키텍처를 Qwen 3.8-Flash-Next를 통해 프리뷰로 선보이고, 오픈웨이트로 공개. Qwen 4는 장기 컨텍스트 지원과 에이전트 워크로드의 연산, 메모리 비용 절감을 핵심 방향으로 설정

중국 AI 모델의 가성비 점검: 기존 딥시크와 샤오미는 극한의 저가 정책을 펼쳤으며, Z AI는 프론티어 모델 대비 한 티어 낮은 성능에 저렴한 가격 포지셔닝 구축. 지금도 중국 AI 모델의 API 가격 자체는 상대적으로 낮게 설정. 다만 단순한 API 가격 간 비교가 아니라 모델을 활용하고 에이전트를 구동할 때 수반되는 토큰량을 활용한 '작업당 비용'과 실제 운용성의 중요성 상승. 작업당 비용 기준 미국과 중국의 AI 모델은 서로 물고 물리는 상황

오픈웨이트에 붙은 상업적 조건: 중국 AI 모델의 또 다른 특징은 오픈웨이트 추구. 하지만 최근 상업적 이용 자체와 수정, 파인튜닝, 파생 모델 구축은 허용하지만, 기존 Apache 2.0 및 MIT 계열의 자유로운 라이선스에서 벗어나 일정 규모 이상의 상업 사용자에게 추가 조건을 부과하기 시작. 적절한 수익 추구 전략의 필요성 시사

(다음 페이지에 계속)

중국 AI 업데이트 - Kimi에 이어 GLM과 Qwen

문샷 AI의 Kimi K3는 중국 AI 모델이 본격적인 프론티어 경쟁에 돌입하는 시작을 알렸다. 2.8T 파라미터로 오픈 웨이트 최대 규모를 기록하며 반도체 규제에 따라 불가능해 보였던 스케일링에도 성공했다. 물론 높지 않은 API 가격에도 불구하고 대규모 출력 토큰 사용에 따라 작업당 비용의 강점은 희석되었고, 과추론, 느린 속도, 벤치마크 대비 부진한 실체감, 유저 경험 측면 격차와 같은 단점도 존재했다. Kimi K3는 아직까지 AAIL 기준 중국 모델 1위 자리를 지키고 있지만, 이후 중국 AI 모델의 업데이트를 주도하는 것은 Z AI의 GLM과 알리바바의 Qwen이다.


특히 Z AI의 GLM-5.3은 GLM-5.2(743B)와 동일한 베이스 모델을 활용하고, 모든 성능 개선을 사후학습 및 장기 RL 스케일링만으로 달성했다. 모델 사이즈를 키우지 않고도 Kimi K3를 추격하는데 성공한 셈이다. Ox Alpha라는 이름으로 테스트된 GLM-5.3-Flash는 320B(활성 18B)의 작은 규모에도 프론티어 모델군과 격차를 상당히 축소했다.

알리바바는 Qwen 3.8 시리즈를 대형 모델(2.4T)와 소형 모델(27B)로 분화하는 전략을 가져가고 있다. 또한 차세대 Qwen4에 적용될 신규 아키텍처를 Qwen3.8-Flash-Next를 통해 프리뷰로 선보이고, 오픈 웨이트로 공개하기도 했다. Qwen 4는 장기 컨텍스트 지원과 에이전트 워크로드의 연산, 메모리 비용 절감을 핵심 방향으로 설정하고 있다.

딥시크는 기존 프리뷰였던 V4 시리즈를 7월 말~8월 초 정식 출시했다. V4 Flash는 대규모 모델 성능 개선에 성공했지만, 기대를 모았던 V4 Pro는 개선폭이 제한적이었다. 미니맥스와 샤오미는 아직 7월 이후 프론티어 레벨에서 경쟁하는 신규 모델 업데이트가 부재하다. 미니맥스의 차기 모델 M3.1과 M3-Pro(3T)는 9월 이후출시를 타겟으로 하고 있다.


오히려 텐센트가 770B(활성 49B) 파라미터 모델 Hy4를 프리뷰로 공개하며 역대 모델 세대교체 중 가장 큰 성능 향상을 달성했다. 다만 초기 버전으로 지나치게 오래 추론하거나 자체 결과를 과도하게 검증하는 문제가 있다고 자체적으로 인정했다. Hy 4 프리뷰는 아직 서드파티 평가가 충분히 진행되지 않았다. 향후 사전학습과 사후학습의 추가 개선에 따른 성능 향상은 주목할 필요가 있다.

미국과 중국 모델 간 격차



자료: Artificial Analysis, 삼성증권

주요 AI 모델 AAIL 점수



자료: Artificial Analysis, 삼성증권

중국 AI 모델의 가성비 점검

중국 AI 모델의 가장 큰 특징은 가성비다. 기존 딥시크와 샤오미는 극한의 저가 정책을 펼쳤으며, Z AI는 프론티어 모델 대비 한 티어 낮은 성능에 저렴한 가격 포지셔닝을 가져갔다. 지금도 중국 AI 모델의 API 가격 자체는 낮게 설정되어 있다. 다만 단순한 API 가격 간 비교가 아니라 모델을 활용하고 에이전트를 구동할 때 수반되는 토큰량에 기반한 '작업당 비용'과 실제 운용성의 중요성도 높아지고 있다.

AAI 평가에 활용되는 토큰량을 통해 간접적으로 확인할 수 있는 모델 별 작업당 비용에서 중국 모델 특유의 가성비의 메리트는 다소 희석되고 있다. 예를 들어 GPT 5.6 Sol의 API 가격은 인풋 \$4 및 \$20(혼합 \$3.1)이지만, 작업 당 비용은 \$0.95로 Grok 4.6(\$0.94)나 Kimi K3(\$0.84)와 격차가 크게 나지 않는다. 또한 딥시크의 V4 모델 가격 인상도 기존 내러티브에 찬물을 끼얹었다. 피크 요금제 기준 V4 Pro의 캐시 인풋은 12배 V4 Flash는 5배 인상되었다.


미국 AI 모델의 반격도 상당히 거세게 이루어지고 있다. 오픈AI는 최적화와 효율화 추구를 통해 GPT-5.6 시리즈의 가격을 연쇄적으로 인하하고 있고, 스페이스XAI의 Grok과 메타 Muse Spark가 새롭게 등장하며 미국 모델의 가격 대비 성능 경쟁력을 높이고 있다. 물론 앤스로픽은 여전히 높은 가격을 설정하고 있지만, 이를 제외하면 작업당 비용 기준 미국과 중국의 AI 모델은 서로 물고 물리는 상황이다.

딥시크 V4 시리즈의 API 가격 인상 수준

(\$/백만토큰)	V4Pro				V4Flash			
	기존	신규 오프피크	신규 피크	(피크/기존, 배)	기존	신규 오프피크	신규 피크	(피크/기존, 배)
캐시 인풋	0.003625	0.022	0.044	12.1	0.0028	0.007	0.014	5.0
인풋	0.435	0.66	1.32	3.0	0.14	0.22	0.44	3.1
아웃풋	0.87	1.98	3.96	4.6	0.28	0.66	1.32	4.7


자료: DeepSeek, 삼성증권 정리

주요 AI 모델 작업 당 비용



자료: Artificial Intelligence, 삼성증권

주요 AI 모델 API 가격



참고: 캐시:인풋:아웃풋=7:2:1 기준 혼합 가격

자료: Artificial Intelligence, 삼성증권

오픈웨이트에 붙은 상업적 조건

중국 AI 모델의 또 다른 특징은 오픈웨이트 추구다. 하지만 최근 상업적 이용 자체와 수정, 파인튜닝, 파생 모델 구축은 허용하지만, 기존 Apache 2.0 및 MIT 계열의 자유로운 라이선스에서 벗어나 일정 규모 이상의 상업 사용자에게 추가 조건을 부과하기 시작했다.

가장 강화된 조건을 부과한 것은 문샷 AI의 Kimi K3다. 문샷 AI는 Kimi 2.6 모델에서도 이미 Modified MIT 라이선스로 대형 서비스의 모델명 표시 의무를 부과했다. 이를 강화한 K3 라이선스는 MaaS 사업자와 계열사의 12개월 합산 매출이 2,000만 달러 초과시 문샷 AI와 별도 계약을 진행해야 한다는 조건을 추가했다. 최근 미국 빅 3 클라우드 기업과 최대 30% 수준의 매출 공유 협상을 진행한다는 내용도 변화된 라이선스 조건을 기반으로 한다.

알리바바는 기존 Qwen 3.5와 3.6의 Apache 2.0 라이선스에서 Qwen 3.8는 자체 Qwen 라이선스로 전환했다. 사업자와 계열사 합산 매출이 5,000만 달러를 초과할 경우 별도 라이선스 취득이 필요하다. MaaS 뿐 아니라 AI 코딩, 오피스 생산성 제품은 AI Work Assistant까지 대상에 포함된다.

Z AI도 GLM-5.3에서 GLM-5.2의 MIT 라이선스에서 변화한 자체 라이선스를 도입했다. 다만 MaaS 사업자 대상 12개월 합산 매출 100억 달러 초과 시 보안 심사가 필요한 조건으로 상대적으로 느슨하다. 또한 브랜딩 의무가 없다는 점도 특이점이다.

이러한 변화가 오픈웨이트에서 벗어나 미국과 유사한 폐쇄형으로의 변화를 가리키는 것은 아니다. 다만 딥시크의 API 가격 인상과 연결 지어본다면 중국 AI 모델 기업 입장에서 적절한 수익 추구 전략이 필요하다는 것을 시사한다.

중국 주요 신규 모델의 라이선스 변화 정리

모델	Kimi K3	Qwen 3.8 Max	GLM-5.3
이전 세대 라이선스	Modified MIT	Apache 2.0	MIT
이전 상업 조건	대형 서비스 모델명 표시	X	X
최신 라이선스	K3 라이선스	Qwen 3.8 Max 라이선스	GLM-5.3 라이선스
일반 상업 이용	O	O	O
수정, 파인튜닝, 파생 모델	O	O	O
추가 규제 대상	MaaS(Model As A Service)	Maas + AI Work Assistant	MaaS
매출 임계값	2,000만 달러	5,000만 달러	100억 달러
매출 산정 범위	라이선스 사용자 + 계열사 매출 합산	라이선스 사용자 + 계열사 매출 합산	라이선스 사용자 + 계열사 매출 합산
임계값 초과 시	별도 계약	별도 라이선스 취득	보안 심사 통과
모델명 표시 의무	O	O	X
표시 기준	MAU 1억 초과 또는 월 매출 2,000만 달러 초과	MAU 1억 초과 또는 월 매출 2,000만 달러 초과	X
내부 사용 예외	O	O	별도 명시 X
공식 추론 이용 제외	O	별도 명시 X	별도 명시 X

자료: 각 사, 삼성증권 정리

Z AI – GLM-5.3과 GLM-5.3-Flash로 파레토 프론티어 장악

동일 베이스 모델로 프론티어 수준을 달성한 GLM-5.3


Z AI의 GLM-5.3은 GLM-5.2와 동일한 베이스 모델(743B)를 활용하면서도 사후학습 및 장기 강화학습(RL) 스케일링을 통해 성능 개선을 달성했다. 특히 코딩, 에이전틱 및 사이버 보안 역량이 강화되었다. AAI 점수는 60점으로 Kimi K3와 동률을 이뤘다. API 가격은 인풋 \$1.4 및 아웃풋 \$4.4로 혼합 \$0.9/백만토큰이고, 작업 당 비용은 \$0.68로 유사한 지능대에서 파레토 프론티어를 차지했었다.

GLM-5.3은 Z AI의 가장 강력한 사이버 보안 모델이기 때문에 사이버 역량의 이중 활용 위험을 고려해 단계적 출시 방침을 가져갔다. 보안 파트너 대상 통제 평가 → API 접근 확대 → 안전성 평가와 보강을 거쳐 모델 웨이트가 기존 타임라인 대로 8월 말 공개되었다.

기술적으로 사후학습에 대한 디테일은 크지 않았다. 대규모 강화학습의 병목을 해결하기 위한 자체 개발 RL 인프라인 slime이 강조되었지만, GLM-5 출시에서도 언급된 바 있었고, 이후 모델에서 학습 처리량 및 효율 개선에 주요한 역할을 하고 있다. 물론 GLM-5.3 학습에서는 추가 고도화와 최적화가 진행되었을 것이다.

Z AI 창업자 탕제(Tang Jie)는 GLM-5.3 출시 이후 스케일링에는 하나 이상의 조절 다이얼이 있다는 코멘트를 남겼다. GLM-5.3은 가장 확장할 여지가 많이 남아있는 영역인 사후학습이라는 다이얼을 돌린 셈이다. 다른 요소들의 스케일링도 끝난 것이 아니다. 향후 베이스 모델의 크기, 사전학습 데이터, 컴퓨팅 자원 모두 추가적 스케일링 대상이다

파레토 증거가 모델에서 파레토 프론티어를 차지한 GLM-5.3-Flash




자료: Artificial Analysis, 삼성증권

스텔스 모델 Ox Alpha의 정체. GLM-5.3-Flash


추가로 AI 산업을 뒤 흔든 모델은 OpenCode와 OpenRouter를 통해 비공개로 테스트된 Ox Alpha다. 당시 1주일 무료 제공과 Zero Data Retention, 하루 100조 토큰 처리 용량을 제시했고, DeepSWE와 같은 일부 벤치마크에서 높은 성능을 보이며 주목을 받았다. 기술적 특징 측면에서 Tokenizer와 비디오 인코더의 유사성, 출력 스타일과 오디오 입력을 거부하는 방식에서 유사한 패턴이 관찰된 Z AI의 GLM 계열이 유력한 후보로 떠올랐고, 실제 정체도 GLM 5 시리즈의 최초 네이티브 멀티모달 모델 GLM-5.3-Flash로 밝혀졌다. 초기 막대한 수요에 따라 8/24일 주간 Z AI의 OpenRouter 토큰 점유율은 23%(Ox Alpha 19% + 기타 Z AI 모델 4%)로 딥시크(16%)를 역전하기도 했다

Ox Alpha의 OpenRouter 주간 토큰량



자료: OpenRouter, 삼성증권

Ox Alpha의 OpenCode 주간 토큰량



자료: OpenCode, 삼성증권


GLM-5.3-Flash의 모델 사이즈는 320B(활성 18B)로 GLM-5.3 대비 작은 구조를 채택했으며, 모델 가중치를 MIT 라이선스로 풀었다. AAI 57점으로 GLM-5.3(60점)과 3점 차이밖에 나지 않지만, 작업 당 비용 \$0.09로 GLM-5.3(\$0.68) 대비 7.5배 저렴하다. API 가격도 인풋 \$0.15 및 아웃풋 \$0.50/백만토큰으로 GLM-5.3의 10%대 수준이다. Index 평가에서 아웃풋 토큰 1.49억 개를 활용해 토큰 효율성 자체는 다소 아쉽지만, 낮은 단가로 경쟁력을 확보했다.

효율성은 작은 활성 파라미터 사이즈, 45개로 축소된 레이어(vs GLM-4.5 92개), 선형 및 희소 어텐션을 결합한 하이브리드 아키텍처 구조, 인덱서의 지연시간과 메모리 오버헤드를 줄이기 위한 IndexPool 도입 등을 통해 확보했다. 특히 GLM-5.3 대비 어텐션 연산량 3배, KV 캐시 4.4배를 절감했다.

초기 테스트 과정의 트래픽을 전부 중국산 AI 칩으로 처리했다는 점도 주요한 특징이다. 중국산 칩은 엔비디아 GPU 대비 개별 칩의 연산 성능과 메모리 용량, 대역폭의 한계 등을 가진다. 이를 극복하기 위해 모델에 맞춘 전용 추론 시스템과 양자화, 메모리 최적화 기술이 적용되었다. 최적화를 통해 동일 하드웨어 기준 서버 능력은 3배 향상되었고, 토큰당 비용과 하드웨어 효율을 주류 엔비디아 GPU 수준까지 개선했다고 주장했다.

칩 자체 성능의 약점을 모델 구조와 소프트웨어 최적화로 보완해 국산 칩으로도 프런티어급 모델을 경제적인 수준에서 대규모 서비스할 수 있다는 사례가 된다. 또한 GLM-5.3 기반 인프라 에이전트는 커널 개발 및 최적화, 병목 진단, 서버 스택 개선에 직접 활용되어 모델이 자신을 구동하는 인프라를 최적화하는 피드백 루프도 활용되었다. 재귀개선 사이클의 지속이다.

GLM 5.3 Flash의 아키텍처와 극한의 효율성 추구



자료: Z AI, 삼성증권

알리바바 – Qwen 3.8 시리즈와 차세대 아키텍처

알리바바는 Qwen 3.8 시리즈를 2.4T 규모 Max 모델과 27B 규모 소형 모델로 분화하는 전략을 펼치고 있다. Qwen 3.8 Max(2.4T)의 AAI 점수와 작업 당 비용은 각각 58점 및 \$0.81이다. 모델 사이즈 확대에 기반한 성능 향상에 대한 기대를 모았지만 Kimi K3를 넘어서지는 못했다.

물론 Qwen 3.7 Max 대비 점수 상승을 달성했으나 아웃풋 토큰이 1억 개에서 1.45억 개로 증가하며 API 가격이 하락했음에도 작업 당 비용은 높아지는 결과로 이어졌고, 파레토 프론티어를 달성하지 못했다. 오히려 작은 사이즈의 Dense 모델 Qwen 3.8 27B가 AAI 점수 52점과 작업 당 비용 \$0.37(API 가격 인풋 \$0.5 및 아웃풋 \$3.0)을 달성했고, Apache 2.0 라이선스와 로컬 구동이 가능한 사이즈로 주목받았다.

하지만 알리바바는 차세대 아키텍처에 비기를 숨겨두고 있다. Qwen4에 적용될 신규 아키텍처를 적용한 프리뷰 모델인 Qwen 3.8 Flash Next는 오픈웨이트로 공개되었다. 과거 Qwen 3 Next에 도입되었던 Gated DeltaNet(GDN) + Gated Attention 하이브리드 설계가 이후 시리즈 전반에 적용된 것과 마찬가지로 차세대 아키텍처를 정식 모델 출시에 앞서 공개하는 전략이다.


Qwen 3.8 Flash Next는 125B의 메인 모델과 51BN-gram 임베딩으로 구성되며, 활성 파라미터는 6B다. 모델은 Attention, Residual, Embedding, Optimization의 4가지 측면에서 체계적으로 업그레이드되었다. 단순 모델 성능 향상뿐 아니라 연산 효율성, 모델 캐파, 학습 안정성 개선을 목표로 했다. Qwen 3.7 Plus와 비교하면 학습 비용을 1/9로 낮추면서 장기 컨텍스트와 에이전트 성능을 높이는 것이 설계의 핵심이다. AAI 점수 56점과 작업 당 비용 \$0.10로 GLM-5.3 Flash 출시 전까지는 해당 구간의 파레토 프론티어를 달성했었다. 다만 실험적 아키텍처의 프리뷰 모델이라는 점을 감안하며 추가 개선 여지가 존재한다.

알리바바 Qwen 3.8 Flash Next에서 보여준 차세대 아키텍처

4대 축	핵심 기술	구조 및 작동 방식	핵심 효과
Attention (어텐션)	GDN(Gated DeltaNet) + QSA(Qwen Spare Attention)	- 레이어 4개 중 3개는 GDN으로 과거 정보를 고정 - 1개는 QSA로 필요한 컨텍스트를 검색 - QSA는 토큰 대신 마이크로 블록 단위로 중요 구간을 선별	- 장기 컨텍스트의 어텐션 인덱싱 비용 절감 - 1M 컨텍스트에서 프리필 최대 7.6배, 디코드 4.9배 가속
Residual (잔차)	Gated Residual(GR)	- 하나의 잔차 정보 흐름을 4개의 병렬 브랜치로 확장 - Dynamic Gate로 각 브랜치의 읽기쓰기 조절 - 잔차 상태는 FP8 저장 가능	- 초기 정보의 희석을 줄이고 Cross-layer 정보 전달 및 학습 안정성 개선. 메모리 트래픽 절감
Embedding (임베딩)	N-gram Embedding	- 현재와 이전 토큰 로컬 패턴을 별도 임베딩 테이블에서 조회 - 추가 51B 파라미터를 호스트 메모리에 저장하고 필요 시 미리 불러오는 방식	- 실제 연산량을 거의 늘리지 않고 모델의 기억 용량 확대 - GPU 메모리 부담 최소화
Optimization (최적화)	Muon + AdamW	- Attention, GDN, MoE에는 Muon, 임베딩, 라우터 등에는 AdamW 적용 - 새로운 구조에 맞춰 스케일링 법칙 재설계	- 더 큰 학습률과 배치 크기를 안정적으로 사용해 학습 수렴 속도와 대규모 병렬 학습 효율 개선

자료: Qwen, 삼성증권

Qwen 3.8 Flash Next의 아키텍처



자료: Qwen, 삼성증권

Z AI(02513 HK) - 1H26 실적 발표

Z AI의 26년 상반기 매출은 9.56억 위안(=약 1.42억 달러, +399.7% YoY)으로 성장 가속화를 시현했다. 특히 오픈 플랫폼 및 API 매출은 8.25억 위안(+2,736% YoY)으로 전체 매출의 86.5%를 차지했다. 기업용 에이전트 매출이 304% 성장한 반면, 기업용 범용 대규모 모델 매출은 56.4% 감소하며, 온프레미스 모델 판매에서 클라우드/API와 에이전트 중심으로 사업구조가 변화하고 있다.

MaaS ARR은 3월 2.5억 달러 → 7월 10억 달러 → 8월 16억 달러(월 매출 기준) 및 20억 달러(최근 1주 매출 기준)으로 급증했다. 8월 한달 API 매출만으로 상반기 전체 API 매출을 넘어선 수준이다. 연말 MaaS ARR 가이드는 24억 달러도 기존 10억 달러에서 상향되었다. MaaS 토큰량은 연초 대비 40배 이상, Coding Plan은 23배 이상 증가한 가운데 평균 API 판매가격도 101% 상승했다. 신규 모델 출시 때마다 MaaS 플랫폼 호출량은 2배씩 증가했다. 일간 토큰 호출량은 40조 개 수준이다. MaaS 유저 740만 명(vs 6월 말 580만 명)으로 연초 대비 +144%, 유료 DAU +603%의 고성장세를 이어가고 있다. 매출 상위 10개 고객의 일평균 호출량도 약 98배 증가했다. 단순한 가격 탄력성이 아니라 성능 개선과 실제 제품 도입 확대가 다양한 지표 성장을 견인하고 있다.

오픈 플랫폼 및 API 매출총이익률(GPM)은 -0.4%에서 24.6%로 개선되었다. 토큰당 추론 비용은 연초 대비 80% 하락했고, 컴퓨팅 투자 1위안당 API 매출을 의미하는 Compute Multiplier(컴퓨터 배수)가 전년 대비 14배로 컴퓨팅 공급 효율 개선을 시사하고 있다. 12-18개월 내 GPM 50% 이상 달성을 목표로 제시했다. 다만 저마진 클라우드/API 비중 급증으로 전체 GPM은 기존 50%에서 하락했다.

최신 모델 GLM-5.3은 GLM-5.2와 동일한 아키텍처와 파라미터를 사용하고 사후학습 규모의 확대만을 통해 성능 개선을 달성했다. Z AI의 사후학습은 데이터, 중간학습, 알고리즘, 엔지니어링 및 환경의 4개 축으로 진행되었다. 또한 10만 장의 중국산 AI 칩을 대규모 추론에 활용하고 있다. GLM-5.3 Flash는 중국산 칩 클러스터만으로 출시 초기 6일간 62조개 이상의 토큰을 처리했다. SGLang 기반 전용 엔진과 인코드-프리필-디코드 분리 아키텍처, 양자화, 캐싱 등 인프라 최적화를 통해 동일 하드웨어의 서버 성능을 약 3배 개선했다.

추가적인 실적 내용에서는 여러 AI 산업 트렌드도 재확인할 수 있었다. Z AI는 코딩을 단순한 최종 시장이 아니라 장기 계획, 틀 사용, 오류 복구 등을 학습시키는 핵심 훈련 환경으로 보고 있다. 이를 기반으로 코딩을 넘어 에이전트 → Cowork → 자율 AI로 역량을 확장하고, 수익화 역시 기존 단순 모델 판매에서 API 호출 + 구독 그리고 엔드 투 엔드 작업 결과까지 확대하는 전략이다. 사이버보안은 코딩에서 축적한 역량이 Cowork로 전이된 첫 사례다. 향후 법률, 금융, 데이터 분석 등으로 영역을 확대할 계획이다.

차세대 스케일링에서도 4개의 축이 강조되었다. 단순 파라미터 확대보다 1) 베이스 모델 확장(Base Model Scale), 2) 유효 깊이(Effective Depth), 3) 학습 깊이(Training Depth), 4) 실행 환경(Trask Environment)의 4개 축으로 접근하고 있다. 현재는 학습의 깊이 측면의 한계 수익이 가장 높지만, 베이스 모델 확장으로 돌아갈 계획을 언급했으며, 파라미터 증가를 제한하며, 추론 깊이를 높이는 방식도 초기 검증 중이다.


차세대 대형 베이스 모델은 이미 학습 중이지만, 구체적 파라미터 수는 공개하지 않았다. 차기 모델의 목표는 장기 컨텍스트와 네이티브 멀티모달 성능 강화다. 이와 함께 학습 단계부터 대규모 트래픽을 위한 추론 인프라를 함께 준비하고 있다는 점도 특징적이다. Z AI가 활용하는 컴퓨팅은 자체 보유 클러스터, 임대 컴퓨팅, 구매형 컴퓨팅 서비스 등으로 구성된다. 중국산 칩 활용에 따른 이기종의 컴퓨팅 자원 구성은 고성능 중국산 칩 양산 본격화에 따라 개선될 것으로 예상하고 있다.

다음 핵심 기술 방향으로 언급한 것은 현재 AI 산업의 주요 화두인 RSI(Recursive Self Improvement)다. 모델이 스스로 데이터를 생성하고 에이전트가 훈련 환경을 구축하며 인프라까지 최적화하는 구조로 GLM-5.3 학습 과정에서 실제 추론 엔진 최적화에 활용되고, 생성 환경이 차세대 모델 학습에 사용되는 초기 RSI 루프가 이미 작동 중이라는 코멘트를 남겼다. 다만 여전히 인간의 개입이 상당히 필요한 상황이다.

해외 사업도 로컬 배포에서 API와 오픈 플랫폼 중심으로 전환하고 있고, 해외 CSP와 오픈 모델, 로컬 호스팅, 매출 공유 방식으로 협력하며 1-2개월 내 추가 업데이트 가능성을 언급했다. 프론티어 해외 모델과 격차는 인정하지만 성능 대비 비용의 파레토 프론티어를 경쟁력 포인트로 제시했다.

모델 커머티화에 대한 의견도 주목할 필요가 있다. 공개 벤치마크와 짧은 태스크에서는 성능이 점차 수렴하겠지만, 장기간 실행되고 검증가능한 실제 업무에서는 모델 간 성능 차이가 더 크게 날 것으로 판단하고 있다. 가격 결정력은 토큰 자체가 아니라 토큰이 완수할 수 있는 업무에서 발생하며 모델이 고객 코드베이스, 톨 체인, 데이터, 워크플로우에 깊게 통합되면 프롬프트, 에이전트 워크플로우, 평가 체계 등이 누적되어 단순 API 가격 이상의 전환 비용이 소요된다는 의견이다.

AI 산업 내 패러다임 변화에 따른 SOTA의 정의



자료: ZAI, 삼성증권

GLOBAL EQUITY

2026. 9. 3

글로벌 AI

Z.ai 손익계산서(CNY 기준)

(천 위안)	2022	2023	2024	2025	1H24	1H25	1H26
매출	57,409	124,538	312,414	724,334	44,909	190,877	953,892
성장률(YoY, %)		116.9	150.9	131.9		325.0	399.7
매출원가	26,049	44,056	136,525	427,678	22,950	95,453	702,281
매출총이익	31,360	80,482	175,889	296,656	21,959	95,424	251,611
매출총이익률(%)	54.6	64.6	56.3	41.0	48.9	50.0	26.4
기타 수익	1,784	9,965	19,281	14,839	4,174	4,614	41,436
판매 및 마케팅 비용	15,139	101,198	387,475	390,869	144,194	208,570	177,666
일반 관리비	32,316	66,302	133,603	505,357	51,452	185,165	103,346
R&D 비용	84,377	528,884	2,195,436	3,180,443	859,217	1,594,661	2,131,171
금융자산 손상차손	31	19,786	17,008	21,576	763	10,867	27,416
영업이익	(98,719)	(625,723)	(2,538,352)	(3,786,750)	(1,029,493)	(1,899,225)	(2,146,552)
금융 비용	5,694	26,332	38,321	74,315	12,212	53,270	95,925
관계기업 투자손익	-	(453)	21,254	54,982	324	14,147	144,152
금융상품 고정가치 변동손익	5,972	26,022	66,271	25,278	7,004	9,791	50,385
투자자발행 금융상품 장부가액 변동	(45,209)	(161,471)	(468,859)	(937,362)	(201,174)	(429,295)	(22,090)
세전이익	(143,650)	(787,957)	(2,958,007)	(4,718,167)	(1,235,551)	(2,357,852)	(2,070,030)
법인세	-	-	0	0	-	0	(1,962)
순이익	(143,650)	(787,957)	(2,958,007)	(4,718,167)	(1,235,551)	(2,357,852)	(2,071,992)
순이익률(%)	(250.2)	(632.7)	(946.8)	(651.4)	(2,751.2)	(1,235.3)	(217.2)
주식 기반 보상	1,024	5,502	23,579	558,265	4,217	158,852	85,764
금융 부채 손실	45,209	161,471	468,859	937,362	201,174	429,295	22,090
상장 비용	-	-	0	40,568	-	17,731	0
조정 순이익	(97,417)	(620,984)	(2,465,569)	(3,181,972)	(1,030,160)	(1,751,974)	(1,964,138)
조정 순이익률(%)	(169.7)	(498.6)	(789.2)	(439.3)	(2,293.9)	(917.9)	(205.9)

자료: Z.ai, 삼성증권

온 프리미엄 및 클라우드 주요 지표

	2022	2023	2024	2025	1H24	1H25	1H26
매출(천 위안)							
온 프리미엄	54,815	112,614	263,930	533,955	26,806	161,777	128,716
클라우드	2,594	11,924	48,484	190,379	18,103	29,100	825,176
성장률(YoY, %)							
온 프리미엄		105.4	134.4	102.3		503.5	(20.4)
클라우드		359.7	306.6	292.7		60.7	2,735.7
매출총이익률(%)							
온 프리미엄	53.6	68.2	66.0	48.8	62.6	59.1	37.9
클라우드	76.1	31.0	3.4	18.9	28.6	(0.4)	24.6

자료: Z.ai, 삼성증권

GLOBAL EQUITY

2026. 9. 3

글로벌 AI

사업부분별 주요 지표

	2024	2025	1H25	1H26
매출(천 위안)				
오픈플랫폼 & API	48,484	190,379	29,100	825,176
엔터프라이즈 에이전트	47,492	165,687	13,739	55,561
엔터프라이즈 범용 대형 모델	214,502	365,724	147,555	67,037
기술 서비스 및 기타	1,936	2,544	483	6,118
성장률(YoY, %)				
오픈플랫폼 & API		292.7		2,735.7
엔터프라이즈 에이전트		248.9		304.4
엔터프라이즈 범용 대형 모델		70.5		(54).6
기술 서비스 및 기타		31.4		1,166.7
매출총이익률(%)				
오픈플랫폼 & API	3.3	18.9	(0.6)	24.6
엔터프라이즈 에이전트	49.3	52.3	64.6	35.6
엔터프라이즈 범용 대형 모델	69.6	46.9	58.5	42.3
기술 서비스 및 기타	87.8	90.4	65.8	9.4

자료: Z.ai, 삼성증권

Z.ai 손익계산서(USD 기준)

(천 위안)	2022	2023	2024	2025	1H24	1H25	1H26
매출	8,530	18,505	46,421	107,628	6,673	28,362	141,737
성장률(YoY, %)		116.9	150.9	131.9		325.0	399.7
매출원가	3,871	6,546	20,286	63,548	3,410	14,183	104,351
매출총이익	4,660	11,959	26,135	44,080	3,263	14,179	37,386
매출총이익률(%)	54.6	64.6	56.3	41.0	48.9	50.0	26.4
기타 수익	265	1,481	2,865	2,205	620	686	6,157
판매 및 마케팅 비용	2,249	15,037	57,574	58,079	21,426	30,991	26,399
일반 관리비	4,802	9,852	19,852	75,090	7,645	27,513	15,356
R&D 비용	12,537	78,586	326,216	472,577	127,670	236,948	316,667
금융자산 손상차손	5	2,940	2,527	3,206	113	1,615	4,074
영업이익	(14,668)	(92,975)	(377,170)	(562,667)	(152,971)	(282,203)	(318,953)
금융 비용	846	3,913	5,694	11,042	1,815	7,915	14,253
관계기업 투자손익	0	(67)	3,158	8,170	48	2,102	21,419
금융상품 고정가치 변동손익	887	3,867	9,847	3,756	1,041	1,455	7,487
투자자발행 금융상품 장부가액 변동	(6,718)	(23,993)	(69,667)	(139,281)	(29,892)	(63,788)	(3,282)
세전이익	(21,345)	(117,081)	(439,526)	(701,065)	(183,589)	(350,349)	(307,582)
법인세	0	0	0	0	0	0	(292)
순이익	(21,345)	(117,081)	(439,526)	(701,065)	(183,589)	(350,349)	(307,874)
순이익률(%)	(250.2)	(632.7)	(946.8)	(651.4)	(2,751.2)	(1,235.3)	(217.2)
주식 기반 보상	152	818	3,504	82,952	627	23,604	12,744
금융 부채 손실	6,718	23,993	69,667	139,281	29,892	63,788	3,282
상장 비용	0	0	0	6,028	0	2,635	0
조정 순이익	(14,475)	(92,271)	(366,355)	(472,804)	(153,070)	(260,323)	(291,848)
조정 순이익률(%)	(169.7)	(498.6)	(789.2)	(439.3)	(2,293.9)	(917.9)	(205.9)

자료: Z.ai, 삼성증권

미니맥스(MiniMax, 00100 HK) – 1H26 실적 발표

미니맥스의 26년 상반기 매출은 1.17억 달러(+283% YoY)로 25년(+159% YoY) 대비 성장이 가속화되었다. AI 네이티브 제품은 4,264만 달러(+101%)로 전체 매출의 30.3%, Open Platform 및 엔터프라이즈 서비스 매출 7,393만 달러(+703%)로 63.4%를 차지했다. 해외 매출 비중 60.8%로 25년 상반기 71.8% 및 25년 73% 대비 축소되었다.

8월 ARR은 8억 달러를 돌파했으며, B2B 고객 비중은 80% 이상이다. 사업 구조가 빠르게 기업과 개발자 중심으로 이동하고 있다. 다만 마진은 M3 출시 과정에서 발생한 이슈, 텍스트 모델 중심 믹스 변화, 높은 R&D 지출로 다소 부진했다.

7월 토큰 사용량은 1월 대비 20배 성장했다. 신규 유저 증가와 기존 기업 고객의 사용량 확대가 동시에 기여하고 있다. 모델 성능이 개선되며 기존 고객들은 새로운 유즈 케이스를 추가하고, 강력한 모델이 신규 고객 확보로 직접 연결되고 있다는 내용이다. 또한 사용 패턴은 에이전트 중심으로 이동하며, 반복적 모델 호출과 툴 사용에 따른 유저 당 토큰 소비량의 급증이 확인되고 있다.

모델 관련 업데이트도 있었다. M3 개발 과정에서는 평가와 인프라 측면의 시행착오가 존재했고, 이후 관련 인프라를 재구축해 차세대 모델 개발 속도와 안정성 개선을 달성했다. 차기 모델 M3.1은 학습, 평가, 추론 인프라의 폐쇄형 루프 완성을 주요 목표로 개선 중이며, 3조 파라미터 규모 차세대 모델 M3 Pro는 대규모 스케일에서 학습 효율과 사후학습 문제를 해결하는 것이 목표다.

현재 모델 발전의 핵심 과제로 수백 번 이루어지는 툴 호출과 검증이 필요한 장기 작업의 안정적 수행을 제시했다. 따라서 고품질 데이터와 강화학습(RL)을 활용한 사후학습이 중요하며, 강화학습 스케일링이 모델 개선 속도를 결정할 핵심 요소로 전망했다. 추론 효율성을 단순 API 원가 절감이 아니라 모델 지능을 높이기 위한 핵심 경쟁력으로 규정한 것도 특징적이었다. 사후학습에서 합성 데이터 생성, 강화학습 롤아웃, 평가 등에 필요한 컴퓨팅 대부분이 추론 워크로드이기 때문에 추론 효율은 내부 모델 반복개발 속도와 직결된다는 입장이다. 현재 대규모 모델에서는 1세대 대비 컴퓨팅 효율성을 3배 개선했고, 풀스택 인프라 최적화를 통해 동일 자본으로 가능한 사후학습 스케일링을 3배 확대할 여지가 존재한다.

미니맥스는 자체 인프라, 하이퍼스케일러, 토큰 팩토리를 조합해 컴퓨팅을 확보하고 있다. 자체 인프라는 주로 플래그십 모델 학습에 활용되고 있다. 대규모 자체 학습 인프라의 ETTR(유효 훈련시간)은 97%로 향후 3T 모델과 영상 생성 모델까지 감안해 필요한 컴퓨팅을 선제적으로 확보하고 있다. 추론 수요가 낮은 시간에는 잔여 컴퓨팅을 모델 평가, 알고리즘 검증, 강화학습 등에 활용하며 전체 자원 가동률을 높이는 구조다. 중국산 AI 칩을 이미 일부 사용하고 있으며, 4Q 부터 비중을 확대할 계획이라는 점도 주목할 필요가 있다.

매출 총이익률 개선의 핵심으로는 아키텍처 효율 강화, 컴퓨팅 처리량 증가, 학습 및 추론 자원 통합 활용, 자체 인프라 및 공급망 최적화 등을 꼽았다. 멀티모달 및 차세대 모델의 마진이 상대적으로 높으며, 컴퓨팅 클러스터 효율화가 진행되면 텍스트 모델도 GPM 개선에 기여할 수 있다. 또한 가격 인하와 마진 개선은 상충하지 않으며, 비용 절감 → 가격 인하 → 사용량 확대 → 규모의 경제 → 추가 비용 절감의 선순환 구조가 가능하다는 입장이다.

미니맥스가 추구하는 장기 경쟁력은 단순히 컴퓨팅 확보 규모가 아니라 적절한 아키텍처와 모델 개선 방식을 기반으로 빠르게 반복 개선하는 것이다. 단위 지능 당 비용을 최소화해 더 높은 지능을 더 큰 규모로 공급하는, 지능의 밀도를 높이는 것을 핵심 전략으로 제시하고 있다.

GLOBAL EQUITY

글로벌 AI

2026. 9. 3

미니맥스 손익계산서

(천 달러)	2022	2023	2024	2025	1H25	1H26	24 1Q~3Q	25 1Q~3Q
매출	-	3,460	30,523	79,038	30,429	116,573	19,454	53,437
성장률(YoY, %)			782.2	158.9		283.1		174.7
매출원가	-	4,314	26,785	58,959	26,744	95,760	18,944	40,961
매출총이익	-	(854)	3,738	20,079	3,685	20,813	510	12,476
매출총이익률(%)	-	(24.7)	12.2	25.4	12.1	17.9	2.6	23.3
기타 수익, 순	1,155	8,942	36,151	40,369	20,339	8,039	25,278	31,232
판매 비용	587	22,827	86,995	51,896	32,843	26,973	53,389	39,325
관리 비용	3,213	7,615	14,384	36,813	14,843	30,230	9,610	22,074
R&D 비용	10,560	70,002	188,979	252,771	124,333	296,870	138,684	180,312
금융 부채 손실	60,509	176,826	214,172	1,589,850	253,876	31,025	128,063	313,477
금융 비용	14	61	509	672	325	647	316	511
금융 자산 손상차손	-	3	88	63	(8)	1,104	68	22
세전이익	(73,728)	(269,246)	(468,976)	(1,871,617)	(402,188)	(357,997)	(304,342)	(512,013)
법인세	-	-	-	0	0	0	0	0
순이익	(73,728)	(269,246)	(468,976)	(1,871,617)	(402,188)	(357,997)	(304,342)	(512,013)
순이익률(%)	n/a	(7,782)	(1,536)	(2,368)	(1,322)	(307)	(1,564)	(958)
주식 기반 보상	1,069	3,346	6,823	24,031	6,634	28,208	6,100	8,581
금융 부채 손실	60,509	176,826	214,172	1,589,850	253,876	31,025	128,063	313,477
상장 비용	-	-	-	6,880	2,943	5,733	0	3,675
조정 순이익	(12,150)	(89,074)	(247,981)	(250,856)	(138,735)	(293,031)	(170,179)	(186,280)
조정 순이익률(%)	n/a	(2,574)	(812)	(317)	(456)	(251)	(875)	(349)

자료: MiniMax, 삼성증권

미니맥스 부문별 매출 및 비중

	2022	2023	2024	2025	1H25	1H26	24 1Q~3Q	25 1Q~3Q
매출(천 달러)								
AI 네이티브 제품	-	758	21,805	53,075	21,223	42,644	13,529	38,020
OpenPlatform + 엔터프라이즈 서비스	-	2,702	8,718	25,963	9,206	73,929	5,925	15,417
비중(%)								
AI 네이티브 제품	-	21.9	71.4	67.2	69.7	36.6	69.5	71.1
OpenPlatform + 엔터프라이즈 서비스	-	78.1	28.6	32.8	30.3	63.4	30.5	28.9

자료: MiniMax, 삼성증권

미니맥스 지역별 매출 및 비중

	2022	2023	2024	2025	1H25	1H26	24 1Q~3Q	25 1Q~3Q
매출(천달러)								
중국 본토	-	2,797	9,217	21,375	8,571	45,745	6,768	14,400
기타	-	663	21,306	57,663	21,858	70,828	12,686	39,037
비중(%)								
중국 본토	-	80.8	30.2	27.0	28.2	39.2	34.8	26.9
기타	-	19.2	69.8	73.0	71.8	60.8	65.2	73.1

자료: MiniMax, 삼성증권

Z AI와 미니맥스 1H26 실적의 함의

빠르게 진행되는 중국 AI 기업의 상업화: Z AI는 상반기 매출 1.42억 달러(+400% YoY)를 달성했고, 8월 MaaS ARR 16억 달러 달성 및 연말 가이드스 24억 달러를 제시했다. 미니맥스의 상반기 매출은 1.17억 달러(+283% YoY)이며, 8월 ARR은 8억 달러까지 확대되었다. 현재 매출 런레이트가 훨씬 큰 구간이다.

성장의 본질은 에이전트발 토큰 폭발: Z AI의 토큰 사용량은 연초 대비 40배+, Coding Plan 23배+ 증가했다. 미니맥스도 7월 토큰 사용량은 1월 대비 20배 증가했다. 에이전트가 장시간 추론하고 반복적으로 모델과 톨을 호출하면서 사용자당 토큰 소비량 자체가 구조적으로 상승하기 시작했다.

저가 모델 수요를 넘어: Z AI는 평균 API 가격을 101% 인상했음에도 토큰 사용량이 급증했고, 상위 10개 고객 사용량은 98배 증가했다. 미니맥스 역시 M3/H3 성능 개선 이후 오픈 플랫폼과 ARR 가속을 강조하고 있다. 결국 단순 가격 인하 → 사용량 증가보다는 지능/성능 개선 → 높은 가치의 작업 수행 → 사용량과 지불의사 동반 상승이라는 수요 함수가 나타나는 중이다.

코딩은 에이전트를 만드는 기반: 두 기업 모두 코딩 분야를 단순 공략해야 할 시장으로 보기 보다는 큰 그림을 그리고 있다. 코딩은 검증 가능한 강화학습 환경이며 향후 에이전트 분야 확장을 위한 토대이다. 미니맥스는 코딩에서 장기 작업, 에이전트 워크플로우로 확장하고 있다. Z AI는 명확하게 코딩에서 학습한 장기 계획, 톨 사용, 오류 복구 등을 사이버 보안 분야로 전이해 활용하고 있다.

스케일링은 사후학습과 환경 개선으로 확장: Z AI는 GLM-5.4 개발 과정에서 동일 베이스 모델에 사후학습만 강화해 성능을 개선했다. 미니맥스도 M3 이후 사후학습 규모를 현재보다 최소 3배 이상 확대할 여지가 있다고 설명한다. 제한된 컴퓨팅 환경에서 단순 파라미터 스케일링보다 학습의 깊이와 검증 환경의 확대가 중국 모델의 중요한 추격 수단이 되고 있다.

추론 최적화도 R&D의 스케일링 수단: 미니맥스는 추론 효율 개선이 서버 비용 뿐 아니라 강화학습 룰아웃, 합성 데이터 생성, 평가 등의 속도를 높인다고 강조했다. Z AI도 동일 하드웨어에서 서버 성능을 약 3배 개선했다. 추론 효율성을 개선하면 더 많은 강화학습 데이터를 실험할 수 있고, 더 좋은 모델 개발로 이어지는 일종의 플라이휠이다.

컴퓨터 전략도 효율성 추구: Z AI는 약 10만 장의 중국산 가속기를 실제 추론 단계 투입하고 인프라 에이전트를 활용해 최적화를 진행했다. 미니맥스도 자체 인프라, 하이퍼스케일러, 토큰 팩토리를 병행하며 컴퓨터를 조달하고 최적화하며 ETTR 97% 수준을 언급했다. 4Q부터 중국산 칩 비중을 확대할 계획도 보유하고 있다. 얼마나 많은 GPU를 보유했느냐 보다 주어진 컴퓨터에서 얼마나 많은 유효 토큰과 지능을 생산할 수 있느냐로 경쟁력이 이동하고 있다. 이 과정에서 보유 캐파에 대한 재배분 전략이 나타날 수 있다.

다음 KPI는 이익단: 다음 검증 포인트는 매출 성장이 아니라 이익률이 될 것이다. 토큰 소비가 아무리 빨리 늘어도 추론 비용이 동시에 증가하면 AI 기업의 경제성은 입증되지 않는다. Z AI는 12~18개월 내 GPM 목표로 50% 이상을 제시했다. 미니맥스 역시 컴퓨터 효율성과 인프라 최적화를 강조하고 있다.

(참고) 답시크 랑원평, 투자자 미팅 주요 내용

7월 말 보도된 답시크 랑원평과 투자자 간 미팅에서도 AI 산업 관점에서 중요한 내용이 다수 포함되어 있다.

주제	세부 내용
답시크의 핵심 전략	- 답시크의 장기 목표는 AGI이며, 소비자 서비스와 기업용 API는 AGI 개발 과정에서 발생하는 중간 산출물로 인식 - 범용 모델과 지능을 고도화하면 소비자용, 기업용 제품은 상대적으로 적은 자원만 투입해도 경쟁력을 확보할 수 있다는 입장 - 3D, 영상생성, 월드모델은 현 단계에서 지능의 상한을 높이는 핵심 기술 경로가 아니기 때문에 우선순위를 두지 않음 - 멀티모달은 소비자 제품에 중요하지만 검색과 같은 구성요소일 뿐, 지능 자체나 AGI의 주력 기술은 아니라고 평가 - AI 시대에는 여러 개의 조 단위 기업이 등장할 수 있기 때문에 모든 시장을 장악할 필요 없이, 가장 잘하는 AGI 모델 영역에 집중해도 충분
AGI 기술 로드맵	- AI 발전을 언어모델 → CoT → Agent → 지속학습 → 자기개선 → 구현지능의 단계로 인식 - 지난해의 핵심 기술 단계는 CoT였으며, 올해의 핵심 단계는 Agent라고 평가 - Agent는 AI가 수행할 수 있는 업무 범위를 넓히지만, 장기간 축적된 맥락을 스스로 학습하지 못해 인간 직원을 완전히 대체하기는 어려움 - 인간은 입사 후 몇 달간 조직과 업무환경을 익힐 수 있지만, 현재 AI에는 관련 맥락을 매번 직접 제공해야 한다는 한계 존재 - 진정한 차세대 모델은 단순히 성능, 속도, 비용이 개선된 모델이 아니라 지속학습 능력을 갖춘 모델이어야 한다고 강조 - 지속학습이 가능해지면 AI가 인간이 수행하는 대부분의 일을 처리하고, 자신의 다음 버전과 더 발전된 AI 모델을 직접 연구하는 자기개선 진입 - 자기개선 이후 AI가 로봇과 구현지능을 직접 개발하는 순서가 가장 효율적인 AGI 경로라고 판단 - 이른바 특이점도 갑작스러운 단절보다 AI가 점진적으로 자기개선 능력을 확보하는 연속적인 과정일 가능성이 높다고 평가
Coding Agent와 차세대 모델	- 현 단계에서 가장 중요한 Agent 분야는 Coding Agent라고 평가 - 코딩은 과업과 결과를 비교적 명확하게 평가할 수 있고, 향후 다른 지식노동 자동화로 확장할 수 있어 범용 Agent의 출발점으로 적합 - 금융, 의료, 법률 등 산업별 Agent보다 범용 Agent와 Coding Agent의 능력을 높이는 것이 우선이라는 입장 - 모델이 자체 연구와 개발을 지원하는 것이 AGI에 가장 빠르게 접근하는 방법이라고 판단
상업화와 제품 전략	- 답시크는 상업화를 하지 않는 회사가 아니라, 상업화를 최종 목표로 삼지 않는 회사라고 설명 - 소비자 서비스와 기업용 API 사업을 운영하지만, 슈퍼앱이나 차세대 바이트댄스, 텐센트를 만들겠다는 목표는 없음 - 지난해 소비자 트래픽 급증은 사전에 계획한 결과가 아니었으며, 사용자 확보 경쟁이나 대규모 마케팅에도 적극적으로 나서지 않음 - 지난해 업계가 챗봇과 소비자 트래픽을 경쟁했고 올해는 기업용 AI 매출을 경쟁하고 있지만, 핵심 관심사는 AGI 기술 로드맵과 기술 돌파구 - 현재의 소비자용, 기업용 시장은 향후 AGI가 창출할 기회에 비하면 상대적으로 작은 기회라고 평가 - 본격적으로 제품과 상업화 중심 기업으로 전환하는 시점은 아직 상당히 멀다고 판단
API 가격 정책	- API 가격은 매출이나 이익 극대화가 아니라 합리적인 수준의 이익 확보를 기준으로 책정 - 서버와 GPU 장비 구매비를 약 10개월 안에 회수할 수 있는 수준을 합리적인 가격으로 판단 - 현재 가격을 더 높여도 토근 수요가 크게 감소하지 않을 수 있지만, 수요의 가격 비탄력성을 활용해 가격을 올리는 방식은 선택하지 않음 - 저렴하고 성능 좋은 AI를 널리 제공하는 것을 연구개발의 목적이자 성취로 인식 - 최적화를 통한 가격 인하 여지는 있지만, 현재 가격은 대부분의 사용자가 부담할 수 있는 수준. 추가 인하에 따른 수요 증가 효과는 제한적 - 낮은 비용은 판매 전략 뿐 아니라 동일한 컴퓨팅 자원으로 더 큰 모델을 학습하기 위한 핵심 기술 전략
오픈소스 전략	- 오픈소스는 마케팅 수단이나 회사의 비전과 장기 전략에 해당 - 답시크가 직접 서비스하는 모델과 공개하는 오픈소스 모델의 성능을 다르게 운영하지 않고 동일한 모델을 제공한다는 입장 - AI 시장은 장기적으로 GDP의 상당 부분을 차지할 만큼 크기 때문에 한 기업이 독점하기 어렵다고 판단 - 과도한 이익 추구 기업은 더 적은 이익에 만족하는 경쟁자에게 결국 밀릴 수 있으며, AI 시장을 독점하려는 전략은 역사적 흐름과 맞지 않음 - 제3자가 오픈소스 모델을 배포하더라도 자사 수준의 추론비용과 운영 효율을 달성하기 어렵기 때문에 API 사업을 훼손하지는 않음 - 회사 규모가 너무 작으면 모델 운영과 최적화를 수행할 자원이 부족하고, 대기업은 조직적으로 효율적인 실행이 어려워짐 - 현재 답시크의 규모가 오픈소스와 상업화를 병행하기에 적절한 구간이라고 평가 - 오픈소스는 합리적인 이익만 추구한다는 전제 아래 상업모델과 충돌하지 않지만, 100배 수준의 초과이익을 추구한다면 제3자 배포는 위협 - 경쟁사에도 기술적으로 도움을 제공할 수 있으며, AI 생태계 전체의 발전을 지원하는 것이 자사 이익과 충돌하지 않는다는 입장
절제는 AGI 성공 확률을 높이는 전략	- 절제를 윤리적 구호가 아니라 AGI를 실제로 구현할 가능성을 높이는 전략으로 규정 - AI 시장의 잠재적 이익이 충분히 크기 때문에 전체 시장을 독점하려 하지 않고 일부만 확보해도 막대한 사업가치를 창출할 수 있다고 판단 - 단기 수익과 시장점유율 일부를 포기하는 대신 조직 결속력과 생태계의 지지를 확보해 AGI 성공 확률을 높이는 전략 - 더 많은 이익을 가져가겠다는 비전을 가진 기업은 처음부터 많은 저항과 경쟁에 직면. 적은 이익에 만족하는 경쟁자에게 밀릴 수 있다고 주장

자료: 삼성증권 정리

GLOBAL EQUITY

2026. 9. 3

글로벌 AI

주제	세부 내용
API 매출과 수익성 전망	- 기업용 AI 수요가 계속 확대되고 GPU를 충분히 확보할 수 있다면 APIARR 수익달러 달성이 가능하다고 전망 - AI 사업 매출이 약 10억달러에 도달하면 연구개발비와 회사 전체 비용을 충당하고 현금흐름이 흑자로 전환될 수 있다고 언급 - API 매출 확대는 중요한 사업이지만 회사의 최우선 목표는 아님 - API는 별도의 대규모 영업조직과 고객지원 조직 없이도 운영 가능, 모델 경쟁력이 충분하면 사용자들이 자연스럽게 유입 - 현재 기술 수준에서 기업용 AI 시장의 상한은 컴퓨팅 공급보다 실제 수요에 의해 결정될 가능성이 높다고 평가 - 향후 모델 기술이 발전하면 기업용 AI 수요도 지속적으로 확대될 것으로 전망
스케일링과 모델 규모	- 모델 규모, 데이터, 학습량을 늘릴수록 성능이 향상된다는 스케일링 법칙을 여전히 신뢰 - 현재 모델 규모는 충분하다고 판단해 결정된 것이 아니라, 보유한 컴퓨팅 자원으로 감당할 수 있는 범위에서 정해진 결과 - 중국 AI 기업은 스케일링의 한계에 도달한 것이 아니라, 충분한 GPU가 없어 스케일링의 상한을 탐색하지 못한 상태라고 평가 - 더 많은 컴퓨팅 자원을 확보하면 더 큰 모델과 더 많은 연구실험을 수행할 계획 - 모델의 연산효율을 높이는 것은 추론비용을 낮추는 목적뿐 아니라 동일한 GPU로 더 큰 모델을 학습하기 위한 수단 - 대기업은 컴퓨팅 자원을 추가 투입해 비효율을 보완할 수 있지만, 딥시크는 자원이 제한된 만큼 비용효율과 연산효율을 우선시
미국과 중국 AI의 격차	- 미국과 중국의 가장 큰 격차는 인재가 아니라 컴퓨팅 자원이라고 평가 - 중국과 미국의 연구자는 본질적으로 유사한 인재풀에 속하며, 중국 내에도 충분한 우수 인재가 존재한다는 입장 - 인재와 모델 성능의 격차도 결국 얼마나 많은 GPU로 얼마나 다양한 실험을 수행할 수 있느냐에서 발생한다고 판단 - 현재 딥시크는 약 2만장의 H급 GPU 환산 컴퓨팅 자원을 보유하고 있으며, 상당수는 최근 1~2개월 사이 도입 - 향후 수개월간 엔비디아 GPU를 추가로 대규모 구매하고, 합리적인 가격에 확보 가능한 물량은 최대한 구매할 방침 - 조달자금을 6개월 안에 모두 GPU로 전환할 수 있다면 가장 이상적인 상황이라고 평가 - 미국의 최대 모델은 활성 파라미터 약 800B 수준인 반면, 중국은 수십B 수준에 머물러 있어 모델 규모에서 큰 격차가 존재 - 미국 수준의 초대형 모델을 학습하려면 약 5만장의 GB300 또는 약 20만장의 화웨이 950급 카드가 필요할 수 있다고 추산 - 현재는 수십B 활성 파라미터 구간에서 연구를 충분히 수행한 뒤, 자원 확대에 따라 150B~250B 수준으로 확장할 계획
화웨이와 중국산 AI 칩	- 화웨이와 긴밀하게 협력하고 있으며 약 1만6,000장의 화웨이 AI 칩 물량을 확보할 수 있다고 언급 - AI 기반 코드 생성과 TileLang 같은 고급 프로그래밍 언어가 CUDA 생태계의 진입장벽을 빠르게 낮출 것으로 전망 - V3 학습에는 엔비디아 GPU를 사용. SW 측면에서는 엔비디아 생태계 의존도를 줄이고 자체 컴파일러와 TileLang 기반 환경을 활용 - TileLang과 자체 컴파일러를 화웨이 칩으로 이전하면 중국산 칩 생태계 문제는 1년 안에 상당 부분 해소 가능, 핵심 병목은 생산능력 - 화웨이 950 슈퍼노드는 GB200-GB300 작업 대체 가능, 약 4장의 화웨이 카드가 엔비디아 카드 1장 수준. 제품 출시도 약 2년 늦음 - 중국과 미국의 칩 격차를 생태계보다 약 4배의 하드웨어 효율 격차와 약 2년의 시간 격차로 설명
자체 칩과 수직계열화	- 대규모 AI 클러스터는 직접 구축하되, 칩은 외부에서 합리적인 가격에 조달할 수 있다면 자체 개발하지 않겠다는 입장 - AI 애플리케이션부터 모델, 인프라, 칩까지 모든 영역을 직접 통합하는 수직계열화에도 부정적 - 산업별 애플리케이션과 생산성 도구는 파트너와 다른 기업들이 개발하고, 딥시크는 AGI 모델과 핵심 기술에 집중하는 구조를 선호 - AI 시장은 충분히 크기 때문에 하나의 핵심 영역만 차지해도 조단위 기업이 될 수 있다고 판단
글로벌 모델 경쟁	- 장기적으로 주요 대형모델의 절대적인 성능 차이는 축소되고, 경쟁력은 비용, 개발 시점, 사용자 경험에서 결정될 것으로 전망 - 동일한 품질의 서비스를 얼마나 낮은 비용으로 제공할 수 있는지가 가장 중요한 차별화 요소 - 두 번째는 경쟁사보다 몇 개월 먼저 기술을 구현할 수 있는가이며, 사용자 경험과 서비스 충성도는 세 번째 요소라고 평가 - 앤스로픽의 Coding Agent 우위는 장기적 우위라기보다 선발효과에 가깝다고 판단 - 오픈AI와 구글이 장기적으로 모델 선두를 번갈아 차지할 가능성이 높다고 전망 - 딥시크 내부에서도 오픈AI 모델을 앤스로픽보다 더 높게 평가하는 연구원이 상당수 존재한다고 언급 - 중국 AI 기업은 제조업과 유사하게 글로벌 최고 수준에 근접한 성능을 낮은 비용으로 제공하는 역할을 담당할 가능성이 높다고 평가 - 중국이 칩 생산능력, 전력, 산업기반을 바탕으로 미국과 함께 글로벌 AI의 주요 축이 될 가능성을 전망
조직 운영과 인재	- 딥시크의 가장 중요한 핵심 이익이자 최대 위험은 팀의 안정성 - 자금이나 GPU 부족은 연구 일정을 늦출 수 있지만, 핵심 인력이 유지되면 결국 AGI를 구현할 수 있다고 확신 - 최근 자금조달과 스톡옵션 제공으로 핵심 인력의 이탈 위험이 상당 부분 완화됐다고 언급 - 구성원들은 보상만을 목적으로 합류한 것이 아니라 AGI를 실현할 수 있는 연구환경에 매력을 느끼고 있으며, 인력 이동도 적다고 설명 - 회사 운영은 위에서 추진하는 공통 과제와 아래에서 연구자가 자발적으로 제안하는 연구를 병행하는 구조 - 공통 과제가 직원 전체 시간의 절반 이상을 차지하지 않도록 하고, 나머지 시간에는 개인이 중요하다고 판단하는 연구를 자율 수행 - 전통적인 KPI와 강한 위계질서보다 비전, 자율성, 내부 공감대를 중심으로 조직을 운영 - 느슨하고 여유로운 환경이 필요하다는 판단 아래 과도한 야근 요구 x, 미완성 부분을 모두 보완하지 않는 것도 일종의 절제로 인식 - 회사 규모가 커지면 일부 조직구조는 조정될 수 있지만, 비전 중심의 운영 방식은 유지할 계획

자료: 삼성증권 정리

주요 AI 기업의 밸류에이션 점검

앤스로픽은 9월 말~10월 초로 예상되는 IPO를 준비 중이다. 투자자 미팅을 진행하고 있으며, 비공개로 제출한 상태인 S-1 파일은 9/7일 Labor Day 이후로 공개될 것이라는 보도가 있었다. 최신 보도 기준 2조 달러 밸류로 약 1,000억 달러 펀딩 이야기가 나오고 있다. 앤스로픽은 투자자 미팅 과정에서 '28년 매출 1,900-2,000억 달러를 전망했다.

최근 공개된 오픈AI와 앤스로픽의 2Q 실적과 ARR을 두고 기대치 대비 아쉽다는 평가도 나오고 있다. 하지만 오픈AI는 GPT-5.6 시리즈가 나온 7월 이후 추이가 중요하다. 앤스로픽은 과거의 압도적 경쟁력이 다소 희석된 상황이지만, MoM 60~70억 달러 증가세를 유지할 경우 연말 ARR 1,000억 달러 달성도 불가능하지는 않다.

문샷 AI와 딥시크의 상장 계획도 거론되고 있다. 현재 상장 AI 기업(Z AI, 미니맥스)과 미국 프론티어 AI 기업(앤스로픽, 오픈AI), 중국 비상장 AI 기업(딥시크, 문샷 AI)의 밸류에이션과 ARR을 활용한 멀티플을 비교하면 흥미로운 포인트가 있다. 상장 기업과 미국 AI 기업이 상대적으로 낮은 멀티플을 받고 있다는 점이다. 규모면에서 차이가 존재하지만, 중국 AI 기업들의 밸류에이션은 미국 프론티어 AI 기업의 상장 과정에서도 참고할 수 있는 이정표가 될 수 있다.


상장 기업의 경우 락업 이벤트와 AI 산업 전반 조정의 영향이 있고, 비상장 기업 ARR은 보도 기반이기 때문에 정확한 시점을 통일시키기 어렵다는 점을 고려해야 한다. 미니맥스 ARR 8억 달러는 8월 기준이지만, 문샷 AI ARR 3억 달러는 6월 기준이다. Kimi K3가 출시된 7월 이후 매출의 레벨업 가능성이 상당히 높다. 앤스로픽과 오픈AI의 ARR 성장폭은 상당히 때문이다. 또한 딥시크도 1~7월 매출 4.75억 위안(0.7억 달러)로 '25년 연 매출의 10배 수준을 기록하고 있다.

주요 AI 모델 기업 밸류에이션 및 멀티플

기업	밸류에이션 (십억달러)	ARR (십억달러)	멀티플 (배)	참고
앤스로픽	965	65	14.8	7월 ARR
오픈AI	852	40	21.3	7월 ARR
Z AI	64	2	31.8	8월 MaaSARR 1주 기준
미니맥스	14	0.8	17.2	8월 ARR
딥시크	74	1	74.0	신규 펀딩 논의 밸류
문샷 AI	50	0.3	166.7	프리 IPO 밸류, 6월 ARR

자료: 언론 보도, 삼성증권

주요 AI 모델 기업 밸류에이션 및 멀티플



자료: 언론 보도, 삼성증권

Compliance notice

- 본 조사분석자료의 애널리스트는 2026년 9월 2일 현재 위 조사분석자료에 언급된 종목의 지분을 보유하고 있지 않습니다.
- 당사는 2026년 9월 2일 현재 위 조사분석자료에 언급된 종목의 지분을 1% 이상 보유하고 있지 않습니다.
- 본 조사분석자료에는 외부의 부당한 압력이나 간섭 없이 애널리스트의 의견이 정확하게 반영되었음을 확인합니다.
- 본 조사분석자료는 당사의 저작물로서 모든 저작권은 당사에게 있습니다.
- 본 조사분석자료는 당사의 동의 없이 어떠한 경우에도 어떠한 형태로든 복제, 배포, 전송, 변형, 대여할 수 없습니다.
- 본 조사분석자료에 수록된 내용은 당사 리서치센터가 신뢰할 만한 자료 및 정보로부터 얻어진 것이나, 당사는 그 정확성이나 완전성을 보장할 수 없습니다. 따라서 어떠한 경우에도 본 자료는 고객의 주식투자의 결과에 대한 법적 책임소재에 대한 증빙자료로 사용될 수 없습니다.
- 본 조사분석자료는 기관투자가 등 제3자에게 사전 제공된 사실이 없습니다.

삼성증권

삼성증권주식회사

서울특별시 서초구 서초대로74길 11(삼성전자빌딩)
Tel: 02 2020 8000 / www.samsungpop.com

삼성증권 Family Center: 1588 2323

고객 불편사항 접수: 080 911 0900



Member of
Dow Jones
Sustainability Indices
Powered by the S&P Global CSA